Наименование образовательной организации

Факультет / институт

Кафедра

ОТЧЁТ О НАУЧНО-ИССЛЕДОВАТЕЛЬСКОЙ РАБОТЕ

по теме

Методы обучения ансамблей деревьев решений, устойчивых к сдвигу распределения табличных данных

Выполнил: Фамилия Имя Отчество

Группа: Номер группы

Научный руководитель: Фамилия Имя Отчество

Москва — 2026

РЕФЕРАТ

Ключевые слова: ансамбли деревьев решений, случайный лес, градиентный бустинг, сдвиг распределения, обобщение на новые домены, табличные данные.

Объект исследования — ансамбли деревьев решений для классификации и регрессии табличных данных. Предмет исследования — методы повышения устойчивости этих ансамблей к изменению распределения между исходными и целевыми доменами.

Цель работы — экспериментально сопоставить существующие методы при выборе модели только по исходным доменам и установить границы обоснованных выводов об их качестве. Рассматриваются IRF, CRF, интерпретация Meta-forests, MaxRM, Era splitting и Anchor boosting, а также сильные базовые ансамбли.

В отчёте разграничиваются эффект настройки гиперпараметров и вклад исследуемого механизма. Приводятся результаты предварительных серий и нового теста с заранее зафиксированным протоколом. Положительные, отрицательные и неполученные статистические результаты сохраняются; универсальное превосходство методов не предполагается.

СОДЕРЖАНИЕ

РЕФЕРАТ **2**

ВВЕДЕНИЕ **4**

1 Анализ предметной области и существующих решений **5**

1.1 Основные определения и постановка задачи 5

1.2 Типы распределительного сдвига 5

1.3 Рассматриваемые методы 5

1.4 Реализации и критерии сравнения 5

1.5 Вывод по аналитической части 5

2 Методология и результаты экспериментального исследования **6**

2.1 Протокол и источники данных 6

2.2 Выбор гиперпараметров и парные контроли 6

2.3 Метрики и статистический анализ 6

2.4 Результаты и обсуждение 6

2.5 Ограничения исследования 7

2.6 Вывод по экспериментальной части 7

ЗАКЛЮЧЕНИЕ **8**

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ **9**

ПРИЛОЖЕНИЕ А. Реестр экспериментальных материалов **10**

ВВЕДЕНИЕ

Модели табличных данных могут терять качество при переносе между организациями, регионами, временными интервалами и условиями измерения. Высокое качество на случайно выделенной части исходной выборки само по себе не характеризует качество на новом домене.

Цель работы — исследовать методы обучения ансамблей деревьев решений, устойчивых к сдвигу распределения, и экспериментально оценить их применимость при source-only выборе модели. Для достижения цели требуется:

1) определить виды сдвига и условия переноса модели;
2) систематизировать рассматриваемые методы и их реализации;
3) задать воспроизводимый протокол source/target разделения;
4) разделить сравнение настроенных моделей и сравнение отдельных механизмов;
5) проанализировать экспериментальные результаты, отрицательные наблюдения и ограничения.

Работа носит экспериментально-аналитический характер. Разработка нового алгоритма не заявляется. Исследовательские утверждения связываются с конкретными реализациями, протоколами и экспериментальными артефактами.

1 Анализ предметной области и существующих решений

1.1 Основные определения и постановка задачи

Пусть доступны исходные домены $\mathcal{E}_s$ с распределениями $P_e(X, Y)$. Обучение и выбор гиперпараметров используют только эти домены. Для нового домена $t \notin \mathcal{E}_s$ исследуется риск

$$R_t(f) = \mathbb{E}_{(X,Y)\sim P_t}\ell(f(X), Y). \tag{1.1}$$

Наблюдения целевого домена не участвуют в выборе модели. Качество source-валидации и качество переноса рассматриваются как различные характеристики процедуры обучения.

1.2 Типы распределительного сдвига

В эксперименте различаются изменения распределения признаков, условного механизма ответа, долей классов, шума, пропусков и ложных корреляций. Сценарий с пропусками характеризует изменение измерений; он не объявляется чистым covariate shift. При изменении условного механизма существование общей инвариантной функции нельзя предполагать без дополнительных условий.

1.3 Рассматриваемые методы

IRF изменяет критерий построения деревьев с учётом неоднородности доменов [1]. CRF использует ограничения, связывающие качество классификации и доменную информацию [2]. Meta-forests объединяет леса, обученные по исходным доменам [3].

MaxRM рассматривает минимизацию наибольшего эмпирического риска [4]. Era splitting меняет критерий разбиения с использованием групп наблюдений [5]. Anchor boosting использует анкерную постановку для переноса модели [6].

1.4 Реализации и критерии сравнения

IRF, CRF и MaxRM в стенде являются независимыми реализациями; Meta-forests — явно обозначенной интерпретацией. Они не называются точными репликациями авторских исследований. Отдельно учитываются capacity, допустимые разбиения, bootstrap, политика признаков и source-only настройка. В качестве сильных baseline рассматриваются Random Forest, ExtraTrees и HistGBDT.

1.5 Вывод по аналитической части

Сравнение требует раздельно оценивать абсолютное качество модели, преимущество над собственным контролем и воспроизводимость. Совпадение только числа деревьев недостаточно для изоляции механизма.

2 Методология и результаты экспериментального исследования

2.1 Протокол и источники данных

Серии final_v1 и expanded_v2 сохранены как исторические результаты. После их аудита выполнены source-only инженерные исправления, а затем проведена серия tuned_v4 с новым протоколом. Настройки и модели v4 опубликованы до открытия целевых данных [7].

Новые синтетические выборки относятся к известным механизмам генерации. Новые реальные домены — заранее зарезервированные штаты ACS для задач Income и PublicCoverage. Эти задачи принадлежат общей survey family. Для Beijing и Appliances в v4 выполнена только source-настройка: прежние target уже открыты и не являются независимым тестом новых решений.

2.2 Выбор гиперпараметров и парные контроли

Гиперпараметры выбираются по выделенным исходным доменам, без целевых оценок. Настройка выполняется один раз на development source каждого контекста; затем параметры переносятся на новые обучающие выборки. Сравниваются расширенно настроенный pipeline и ограниченный source-selected reference, а также выбранная модель и её структурно сопоставимый контроль.

Meta uniform использует те же обученные members. MaxRM сохраняет bootstrap и структуру деревьев. У Era контроль с нулевой силой критерия сохраняет доменные ограничения допустимости разбиений и не равен обычному HistGBDT.

2.3 Метрики и статистический анализ

Для классификации используется разность AUROC; для регрессии — снижение MSE, делённое на дисперсию полного source. Сначала усредняются целевые домены и model seeds, затем сценарии внутри независимой MC replica.

Основные контрасты проверяются двусторонним точным sign test с единой коррекцией Holm. Нулевые контрасты исключаются из sign test. Маргинальный t-интервал среднего не является одновременным интервалом и относится к иному параметру, чем проверка знаков. Реальные перекрывающиеся resamples анализируются описательно [7, 8].

2.4 Результаты и обсуждение

Завершено 272 заданий и 24 основных тестов; после Holm значимы 15 контрастов [9]. Избранные контрасты представлены в таблице 2.1. Полная таблица и фильтры строк сохранены в экспериментальных артефактах [8].

Таблица 2.1 — Избранные результаты v4; источник: [8]

Метод	Контраст и задача	Эффект	Holm p
IRF	Настройка, классификация	+0.035031	0.046875
CRF	Настройка, классификация	+0.035034	0.046875
META	Механизм, классификация	+0.002372	0.046875
ERA	Механизм, регрессия	+0.014899	0.046875
IRF	Механизм, классификация	-0.000431	0.046875
CRF	Механизм, классификация	-0.001086	0.046875

Классификация: разность AUROC; регрессия: снижение MSE / source variance.

Расширение настройки улучшило ряд моделей относительно ограниченного reference. При этом положительный вклад механизма подтверждён не у всех методов. Большой HPO gain не означает, что выигрыш обусловлен DG-регуляризацией, и не гарантирует победы над сильным baseline.

2.5 Ограничения исследования

Синтетические MC replicas не являются выборкой всех табличных задач. Ограниченный поиск не устанавливает глобальный максимум каждого метода; CPU бюджеты различаются. Положительные средние контрасты не означают устойчивости при каждом отдельном сдвиге. Локальные hashes и timestamps не подменяют независимый системный аудит доступа.

2.6 Вывод по экспериментальной части

Экспериментальные данные обосновывают раздельную оценку настройки, механизмов и абсолютного качества. Окончательная редакция главы должна включать полный разбор v1/v2/v4, таблицы реальных задач и анализ каждого вида сдвига; исходные материалы сохранены в репозитории.

ЗАКЛЮЧЕНИЕ

В работе сформулирована source-only постановка переноса ансамблей деревьев между доменами, выделены механизмы распределительного сдвига и заданы условия сопоставимого экспериментального сравнения.

Проведённые серии показывают пользу тщательной настройки отдельных моделей и более ограниченную полезность самих DG-механизмов. Универсальное превосходство над сильными базовыми ансамблями не установлено. Обоснованность вывода зависит от реализации, протокола выбора модели и типа сдвига.

Дальнейшие новые решения должны проверяться на новых заранее зафиксированных целевых данных. Уже открытые домены не могут повторно использоваться как независимое подтверждение.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Yufan Liao and Qi Wu and Xing Yan. Invariant Random Forest: Tree-Based Model Solution for OOD Generalization. 2024. https://ojs.aaai.org/index.php/AAAI/article/view/29283.

2. Camilla Lingjærde and Geir Kjetil Sandve and Arnoldo Frigessi and Sylvia Richardson and Johan Pensar. Constrained Random Forest for Domain-Generalizable Classification. 2026. https://proceedings.mlr.press/v337/lingjaerde26a.html.

3. Yuyang Sun and Panagiotis Kosmas. Meta-forests: Domain generalization on random forests with meta-learning. 2024. https://proceedings.mlr.press/v222/sun24b.html.

4. Francesco Freni and Anya Fries and Linus Kühne and Markus Reichstein and Jonas Peters. Maximum Risk Minimization with Random Forests. 2026. https://arxiv.org/abs/2512.10445.

5. Timothy DeLise. Era splitting - Invariant learning for decision trees. 2026. https://doi.org/10.1016/j.eswa.2025.129687.

6. Malte Londschien and Manuel Burger and Gunnar Rätsch and Peter Bühlmann. Domain generalization and adaptation in intensive care with anchor regression. 2026. https://doi.org/10.1093/rssdat/udag001.

7. Протокол свежего теста v4. Версия репозитория `a2e54a1`. https://github.com/uBaxa0IQ/coral-forest-dg/blob/a2e54a1f3fe933c2c7ec20e902f8e0571b412c28/runs/tuned_v4/final_protocol.json.

8. Предзаданные контрасты и результаты v4. Версия репозитория `a2e54a1`. https://github.com/uBaxa0IQ/coral-forest-dg/blob/a2e54a1f3fe933c2c7ec20e902f8e0571b412c28/reports/tuned_v4/hypothesis_tests.csv.

9. Проверка целостности и воспроизводимости v4. Версия репозитория `a2e54a1`. https://github.com/uBaxa0IQ/coral-forest-dg/blob/a2e54a1f3fe933c2c7ec20e902f8e0571b412c28/reports/tuned_v4/final_integrity.json.

ПРИЛОЖЕНИЕ А

Реестр экспериментальных материалов

Программный стенд и журналы находятся в `code/`; документация и литература — в `materials/`; результаты серий и материалы отчёта — в `nir/`; материалы будущей ВКР — в `vkr/`.

— протоколы и source receipts: `code/runs/`;

— исходные таблицы, графики и отчёты: `nir/results/`;

— реестр источников и локальные полные тексты: `materials/literature/`;

— карта переноса и проверка сохранности: `materials/repository_layout/`.

Точные значения, определения эффектов, строки таблиц и контрольные суммы следует проверять по исходным артефактам [8, 9]. Начальное наполнение настоящего шаблона не заменяет полный итоговый текст отчёта НИР.